Inférence Causale

Hani Zaki

Avril 2024

Table des matières

1 Introduction : d'où me vient ce mal de tête ? 2

2 Concept de base 2
2.1 Effet causal individuel 2
2.2 Effet causal moyen 3
2.3 Hypothèses importantes de l'inférence causale 3
2.3.1 Cohérence 3
2.3.2 Positivité 3
2.3.3 Interchangeabilité 3

3 Représentation graphique 3
3.1 Diagrammes causaux 4
3.2 Indépendance 4
3.2.1 Indépendance conditionnelle 4
3.2.2 Indépendance marginale 5

4 Variable confondante 6
4.1 Chemin de porte arrière 7
4.2 Critère de la porte arrière 7

5 Techniques d'estimation 8
5.1 Pondération par probabilité inverse 8
5.2 Simulation en R 10

6 Conclusion 12

7 Annexe 13

8 Reference 14

1 Introduction : d'où me vient ce mal de tête ?

Vous vous réveillez un matin avec un terrible mal de tête. Vous repensez à ce qui s'est passé la veille pour essayer de déterminer ce qui a bien pu causer ce mal de tête. Vous vous rappelez avoir eu une journée stressante au travail - le mal de tête est peut-être une réaction au stress que vous avez vécu. Après le travail, vous vous rappelez que vous étiez dans le même bus qu'un homme malade qui toussait sans se couvrir la bouche - vous avez peut-être attrapé sa maladie.

Déterminer la véritable cause d'une réaction est difficile. Plusieurs facteurs peuvent être associés à votre mal de tête, ce qui rend la tâche plus difficile. Comment déterminer la véritable cause lorsque celle-ci est associée à plusieurs autres facteurs ? Là est le problème fondamental de l'inférence causale.

Dans les prochaines sections, nous discuterons des concepts de base en inférence causale, puis nous présenterons les hypothèses nécessaires à la solution du problème fondamental de l'inférence causale. Nous entamerons ensuite les représentations graphiques des relations causales, principalement les diagrammes causaux. Par la suite, nous verrons une technique d'estimation (*IP Weighting*) accompagnée par une simulation en R. Finalement, nous conclurons en résumant ce qui a été vu.

2 Concept de base

Nous débutons tout d'abord par définir certaines notations et certains termes qui reviendront souvent. Tout d'abord, notons Y la variable aléatoire définissant le résultat d'une observation, et A la variable aléatoire définissant le traitement reçu. Dans ce document, la variable A sera considérée comme étant binaire. Nous noterons aussi Y_i^a le résultat potentiel si l'individu i avait reçu le traitement $A_i = a$. Avec ces notations, nous allons maintenant définir deux termes importants : l'effet causal individuel et l'effet causal moyen.

2.1 Effet causal individuel

Nous dirons que le traitement A_i associé à l'individu i a un effet causal sur la réponse Y_i si $Y_i^{a=0} \neq Y_i^{a=1}$. C'est-à-dire, un traitement aura un effet causal sur la réponse d'un individu si la réponse potentielle que l'individu aurait eue en recevant le traitement $a = 0$ est différente de celle qu'il aurait eue en recevant le traitement $a = 1$. Nous notons que l'effet causal individuel dépend des données non observées (réponses potentielles). De ce fait, les effets causaux individuels ne peuvent pas être identifiés, et nous opterons plutôt de calculer l'effet causal moyen.

2.2 Effet causal moyen

Nous dirons que le traitement A a un effet causal moyen sur la réponse Y si $\mathbb{P}(Y^{a=1} = 1) \neq \mathbb{P}(Y^{a=0} = 1)$. C'est-à-dire, un traitement a un effet causal moyen sur une réponse si la probabilité d'observer la réponse d'intérêt sous le traitement est différente de la probabilité d'observer la réponse d'intérêt sans le traitement. Contrairement à l'effet causal individuel, l'effet causal moyen peut être estimé, et est généralement la mesure d'intérêt.

2.3 Hypothèses importantes de l'inférence causale

Nous abordons maintenant trois hypothèses cruciales de l'inférence causale.

2.3.1 Cohérence

L'hypothèse de cohérence stipule que pour un individu i, le résultat observé Y_i lorsque le traitement est $A_i = a$ est le même que le résultat potentiel Y_i^a. Formellement,

$$A_i = a \implies Y_i^a = Y_i$$

2.3.2 Positivité

L'hypothèse de positivité assure que chaque individu a une probabilité non nulle de recevoir chaque traitement. Formellement,

$$P(A = 1) > 0$$

2.3.3 Interchangeabilité

L'interchangeabilité stipule que les résultats observés entre deux individus diffèrent seulement à cause du traitement assigné. Formellement,

$$Y^a \perp A$$

C'est-à-dire que le résultat potentiel est indépendant du traitement reçu.

Un peu plus tard, nous verrons comment ces hypothèses sont utilisés pour dériver une estimation de l'effet causal moyen.

3 Représentation graphique

Dans cette section, nous explorerons comment les concepts théoriques peuvent être visualisés efficacement à l'aide de représentations graphiques. Principalement, nous verrons les diagrammes causaux, qui sont des graphes orientés acycliques. Les diagrammes causaux permettent de visualiser les effets causaux entres différentes variables. Les nœuds représentent les variables aléatoires et les flèches représentent une relation de causalité. La disposition des nœuds est importante, et se fait de gauche à droite, pour indiquer une relation temporelle.

3.1 Diagrammes causaux

On commence tout d'abord par montrer un exemple simple de diagramme causal.

FIGURE 1 – Diagramme causal simple

Le nœud A représente la variable aléatoire définissant le traitement, et le nœud Y représente la variable aléatoire définissant la réponse. La flèche de A vers Y indique que le traitement influence la réponse. En d'autres mots, il y a un effet causal direct de A vers Y. Il est important de noter qu'une flèche n'indique pas si l'effet est bénéfique ou nuisible. Elle indique simplement la présence d'un effet causal. De plus, si une variable a deux causes, comme nous le voyons dans la figure 2, le diagramme ne nous permet pas de déterminer l'interaction entre ces deux causes sur la variable vers laquelle elles pointent. L'aspect important

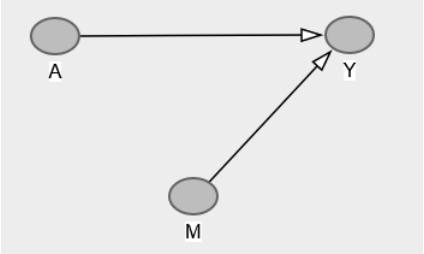

FIGURE 2 – Diagramme causal : deux causes

à retenir ici est que, puisque les diagrammes causaux sont des graphes orientés acycliques, la couverture de Markov peut s'appliquer. Celle-ci nous dit que, sachant les causes directes d'une variable, elle est indépendante de toutes les autres variables. Cela nous mène à parler d'indépendance.

3.2 Indépendance

L'indépendance est une notion importante de la théorie des probabilités. Nous verrons ici comment déterminer si deux variables sont conditionnellement ou marginalement indépendantes en utilisant un diagramme causal.

3.2.1 Indépendance conditionnelle

On reprend les mêmes variables A et Y. Nous ajoutons maintenant une variable K, que nous notons simplement comme étant une variable aléatoire.

Dans les diagrammes qui seront présentés, un nœud rectangulaire signifie que nous supposons avoir observé la variable. En d'autres mots, la variable n'est plus aléatoire car elle est supposée connue. Nous voyons différents cas ci-dessous.

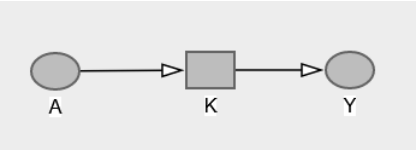

FIGURE 3 – Diagramme causal : indépendance conditionnelle

Dans le diagramme causal de la figure 3, nous dirons que A est conditionnellement indépendant de Y sachant K. En effet, A influence K et K influence Y. Donc, si nous connaissons la valeur de K, l'information donné par A ne nous dit rien de plus sur Y.

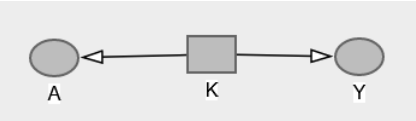

FIGURE 4 – Diagramme causal : indépendance conditionnelle

Dans la figure 4, nous avons encore que A est conditionnellement indépendant de Y sachant K. En effet, K influence à la fois A et Y. Donc, ayant observé K, nous éliminons l'aléatoire qui rendait A et Y dépendants.

3.2.2 Indépendance marginale

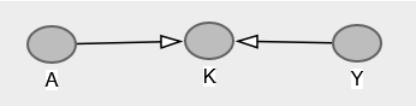

FIGURE 5 – Diagramme causal : indépendance conditionnelle

Finalement, nous avons ici un exemple d'indépendance marginale. La figure 5 montre la variable K comme cause des deux variables A et Y. Nous notons ici que K n'est pas observé. Nous dirons que A et Y sont marginalement indépendants. Si K était observé, A et Y seraient dépendants. La raison est que A et Y influencent ensemble la variable K. Donc, si nous mesurons leur influence, alors nous découvrons leur interaction en K, et nous les rendons ainsi dépendants.

4 Variable confondante

Définition : Une variable confondante est une variable aléatoire qui influence à la fois la variable dépendante (ce qui est mesuré) et la variable indépendante (ce qui est manipulé).

Dans notre cas, la variable dépendante est la variable de la réponse Y, et la variable indépendante est la variable du traitement A. Une variable confondante agit donc à la fois sur le traitement et sur la réponse, ce qui rend l'estimation directe de l'effet causal entre A et Y biaisée. Nous verrons cependant qu'il existe des méthodes pour contrôler l'impact d'une telle variable et ainsi pouvoir définir l'effet causal sans confusion.

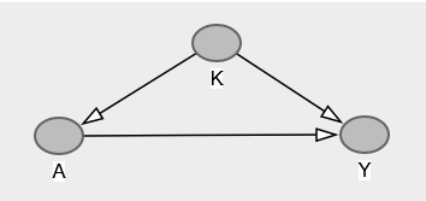

FIGURE 6 – Diagramme causal : Variable confondante K

Nous avons ici un exemple classique de variable confondante. K est une variable aléatoire non observée qui agit à la fois sur A et Y, ajoutant ainsi de la confusion sur la relation causale entre le traitement et la réponse. K est donc une variable confondante.

Comment calculer l'effet causal moyen entre A et Y de manière à ne pas être biaisé par la variable confondante K ? Nous nous rappelons que A a un effet causal moyen sur Y si $\mathbb{P}(Y^{a=1} = 1) \neq \mathbb{P}(Y^{a=0} = 1)$. Nous pouvons donc calculer l'effet causal moyen par $\mathbb{P}(Y^{a=1} = 1) - \mathbb{P}(Y^{a=0} = 1)$, qui peut être réécrit comme étant $\mathbb{E}(Y^{a=1}) - \mathbb{E}(Y^{a=0})$.

Nous avons vu plus tôt que si K est observé, A est conditionnellement indépendant de Y. Donc, dans le cas où K est observé, nous pourrions calculer l'effet causal moyen par $\mathbb{E}(Y^{a=1}|K) - \mathbb{E}(Y^{a=0}|K)$. Nous noterons que $Y^a \perp A|K$, qui est la définition de l'interchangeabilité conditionnelle. Pour calculer l'effet causal moyen en présence d'une variable confondante, nous avons donc besoin de la condition d'interchangeabilité conditionnelle. Le critère de la porte arrière est un critère appliqué au diagramme causaux qui nous permet de déterminer si la condition est présente.

4.1 Chemin de porte arrière

Définition : Un chemin de porte arrière entre un noeud A et un noeud Y est un chemin non orienté qui persiste même lorsque toutes les flèches pointant vers l'extérieur de A sont retirées.

Si nous revenons à la figure 6, nous voyons que A pointe vers Y. Nous voyons aussi un chemin non orienté de A vers Y en passant par K. Si nous retirons la flèche sortante de A, le chemin passant par K persiste. Ce chemin est donc un chemin de porte arrière entre A et Y. Nous définissons maintenant un chemin de porte arrière bloqué.

Définition : Un chemin de porte arrière est bloqué s'il ne permet pas une transmission d'information entre le noeud de départ et le noeud d'arrivée.

Dans notre cas, le noeud de départ est A et le noeud d'arrivée est Y. Nous dirons donc que le chemin de porte arrière entre A et Y est bloqué si, lorsqu'il est considéré isolément, A et Y sont indépendants.

4.2 Critère de la porte arrière

Avant de définir le critère de la porte arrière, nous ajoutons une nouvelle notation. Soit $\mathcal{K}$ un ensemble de variables aléatoires. Nous définissons maintenant le critère de la porte arrière :

Définition : Le critère de la porte arrière est un critère qui permet de déterminer s'il y a interchangeabilité conditionnelle selon $\mathcal{K}$. Les conditions du critère sont les suivantes :

- Tous les chemins de porte arrière de A à Y sont bloqués lorsque nous conditionnons sur $\mathcal{K}$.
- $\mathcal{K}$ ne contient pas de variables enfants de A

On dira donc qu'il y a interchangeabilité conditionnelle si et seulement si $\mathcal{K}$ satisfait le critère de la porte arrière.

On se rappelle que dans le contexte d'un graphe orienté acyclique, un enfant de A est un noeud quelconque, disons B, tel qu'il existe une flèche de A vers B.

Nous reprenons encore une fois la figure 6. Supposons que K est observé. Est-ce que tous les chemins de porte arrière de A à Y sont bloqués lorsque nous conditionnons sur K ? La figure 4, qui correspond au chemin de la porte arrière dans notre exemple, nous dit que A et Y sont indépendants sachant K. Donc la réponse à la question est : oui. Le seul chemin de porte arrière entre A et Y est bloqué en conditionnant sur K.

Nous nous demandons ensuite si $\mathcal{K}$ contient des variables enfants de A. Dans notre exemple, $\mathcal{K} = \{K\}$, et K n'est pas enfant de A, donc non, $\mathcal{K}$ ne contient pas de variables enfants de A.

Les conditions du critère de la porte arrière sont respectées, nous pouvons conclure que la condition d'interchangeabilité conditionnelle (conditionnellement à K) est respectée, et donc que $Y^a \perp A|K$. C'était un exemple simple, mais il est possible d'appliquer ce critère à des situations plus complexes.

Maintenant que nous savons comment déterminer si la condition d'interchangeabilité conditionnelle est respectée, nous allons voir comment estimer l'effet causal moyen en utilisant la méthode de pondération par probabilité inverse, aussi connue en anglais par *IP Weighting*.

5 Techniques d'estimation

5.1 Pondération par probabilité inverse

La méthode de Pondération par probabilité inverse permet d'estimer l'effet causal moyen à partir de données observationnelles où les groupes de traitement ne sont pas assignés aléatoirement. Elle s'appuie sur l'estimation de scores que nous appelons score de propension (ou *propensity score* en anglais), qui représente la probabilité de recevoir un traitement conditionnellement aux covariables, noté ici $\mathbb{P}(A = 1|K)$. Les scores sont utilisés pour pondérer les observations, et ainsi simuler une population où tous les individus ont une chance égale de recevoir l'un ou l'autre des traitements. La formule d'estimation est la suivante :

$$\frac{1}{N}\sum_{i=1}^{N}\frac{\mathbf{1}_{\{A=1\}}Y_i}{\mathbb{P}(A=1|K)} - \frac{1}{N}\sum_{i=1}^{N}\frac{\mathbf{1}_{\{A=0\}}Y_i}{\mathbb{P}(A=0|K)}$$

Cette méthode repose sur les hypothèses que nous avons vues, soit la cohérence, l'interchangeabilité conditionnelle et la positivité conditionnelle [1]. Nous allons prouver que la formule estime bien l'effet causal moyen, et vous verrez comment ces hypothèses sont utilisées.

Démonstration. Nous avons que l'effet causal moyen est défini comme

$$\begin{aligned}\mathbb{E}(Y^{a=1} - Y^{a=0}) &= \mathbb{E}(\mathbb{E}(Y^{a=1} - Y^{a=0})|K) \\ &= \mathbb{E}(\mathbb{E}(Y^{a=1}|K) - \mathbb{E}(Y^{a=0}|K)) \\ &= \mathbb{E}(\mathbb{E}(Y|A=1,K) - \mathbb{E}(Y|A=0,K))\end{aligned}$$

La première égalité est par la double espérance. Pour la deuxième égalité, nous utilisons l'hypothèse d'interchangeabilité conditionnelle, puisque nous avons vu que $Y^a \perp A|K$. La troisième égalité utilise l'hypothèse de cohérence, c'est-à-dire que la réponse potentielle sous $a = 1$ est égale à la réponse observée lorsque

1. $P(A = 1|K) > 0$

l'individu reçoit le traitement. Nous avons maintenant

$$\begin{aligned}
\mathbb{E}(\mathbb{E}(Y|A=1,K)) &= \sum_k \mathbb{E}(Y|A=1,K)\mathbb{P}(K=k) \\
&= \sum_{k,y} y\mathbb{P}(Y=y|A=1,K=k)\mathbb{P}(K=k) \\
&= \sum_{k,y} y\mathbb{P}(Y=y|A=1,K=k)\mathbb{P}(K=k)\frac{\mathbb{P}(A=1|K=k)}{\mathbb{P}(A=1|K=k)} \\
&= \sum_{k,y} y\mathbf{1}_{\{A=1\}}\mathbb{P}(Y=y|A=1,K=k)\mathbb{P}(K=k)\frac{\mathbb{P}(A=1|K=k)}{\mathbb{P}(A=1|K=k)} \\
&= \sum_{k,y} y\mathbf{1}_{\{A=1\}}\frac{\mathbb{P}(Y=y,A=1,K=k)}{\mathbb{P}(A=1|K=k)} \\
&= \mathbb{E}\left(\frac{Y\mathbf{1}_{\{A=1\}}}{\mathbb{P}(A=1|K=k)}\right)
\end{aligned}$$

Les deux premières égalités sont par définition de l'espérance pour des variables aléatoires discrètes. La troisième égalité est sous l'hypothèse de la positivité conditionnelle. L'hypothèse stipule que $P(A=1|K)>0$, et donc nous pouvons l'utiliser pour multiplier par 1. La quatrième égalité est du fait que l'espérance est prise dans le cas où l'individu reçoit le traitement ($A=1$), donc lorsque $A=0$, la somme donne 0. La cinquième égalité est par la formule des probabilités totales. Finalement, la sixième égalité est par définition de l'espérance. En effet, si nous considérons $g(Y,K,A)=\frac{Y\mathbf{1}_{\{A=a\}}}{\mathbb{P}(A=a|K=k)}$, alors

$$\mathbb{E}(g(Y,K,A)) = \sum_{y,k,a} g(Y,K,A)\mathbb{P}(Y=y,A=a,K=k)$$

C'est ce qui conclut la preuve. □

Nous pouvons donc estimer $\mathbb{E}\left(\frac{Y\mathbf{1}_{\{A=1\}}}{\mathbb{P}(A=1|K=k)}\right)$ par la moyenne empirique, qui est

$$\frac{1}{N}\sum_{i=1}^{N}\frac{\mathbf{1}_{\{A=1\}}Y_i}{\mathbb{P}(A=1|K)}$$

et nous reconnaissons cette formule de la formule de l'estimateur utilisant la technique de pondération par probabilité inverse. Pour le terme avec $A=0$, c'est la même démarche. Nous allons maintenant montrer un exemple pratique de l'application de cette méthode en programmant une simulation de la figure 6 avec le langage de programmation `R` et le logiciel *RStudio*.

5.2 Simulation en R

Nous montrons maintenant comment programmer une simulation de la figure 6 avec `R`. Les parties pertinentes du code seront discutées ici, puis le code en entier sera donné en annexe. Pour la simulation, nous dirons que le traitement A est la prise d'un certain médicament, la réponse Y est continue et représentera le nombre de battement par minute du coeur de l'individu. Finalement, la variable confondante K sera l'âge. Nous supposerons que K suit une distribution normale.
Nous définissons tout d'abord la taille de l'échantillon. Ici, Nous choisissons un échantillon de taille 100.

```
n_size <-  100
```

Nous définissons ensuite les paramètres reliés au traitement, les paramètres reliés à la réponse ainsi que les paramètres de la distribution de l'âge.

```
#Definition des parametres du traitement
beta0 <- 0.02 ; beta1 <- 0.012

#Distribution de l'age
agemean <- 45; agesd <- 8

#Definition des parametres de la reponse
beta0.r <- 75 ; beta1.r <- 8.5; beta2.r <- 165
```

`beta2.r` correspond à l'effet causal que nous désirons estimer, c'est-à-dire l'effet du traitement sur la réponse. `beta1.r` correspond à l'effet de l'âge sur la réponse. Pour ce qui est du traitement, `beta1` correspond à l'effet de l'âge sur le traitement. Nous simulons ensuite l'âge des 100 individus en utilisant les paramètres spécifiés et nous ajoutons les valeurs des âges à un tableau que nous avons appelé `mat`.

```
  #Simulation de l'age
  sim.age <- rnorm(n_size, agemean, agesd)
  mat$age <- sim.age
```

Nous calculons ensuite la probabilité des traitements. Puisque c'est une variable binaire, Nous utilisons la distribution binomiale. Nous ajoutons les probabilité à notre tableau.

```
  #Calcul des probabilites de traitement
  prt <- beta0 + beta1*mat$age
  mat$trt <- rbinom(n_size, 1, prt)
```

Nous calculons ensuite la distribution de la réponse. Nous y ajoutons un terme d'erreur simulé d'une normale centrée en 0 et de variance 1.

```
  #Distribution de la reponse avec erreur normal(0,1)
  eps <- rnorm(n_size, 0, 1)
  mat$rep <- beta0.r + beta1.r*mat$age + beta2.r*mat$trt + eps
```

Maintenant que nous avons simulé une réponse, un traitement et un âge pour chaque individu, nous pouvons essayer de calculer l'effet causal. Pour appliquer la technique de *IP Weighting*, il faut calculer les poids, qui sont l'inverse des

scores de propensions. Il faut donc, tout d'abord, calculer les scores de propensions. Le score est défini comme la probabilité de recevoir le traitement sachant l'âge. Nous pouvons donc appliquer une régression logistique du traitement selon l'âge. Cela nous donnera la probabilité de recevoir le traitement pour chaque individu dans l'échantillon. Nous ajoutons les scores dans notre tableau.

```
#Modelisation des scores de propension et cacul de ceux-ci
exp.model <- glm(mat$trt ~ mat$age , data=mat, family = "binomial")
propensity.score <- predict(exp.model, type="response")
mat$pps <- propensity.score
```

Nous calculons ensuite les poids.

```
#Calcul des poids de la methode IP Weighting
ipw.tr1 <- 1/mat$pps[mat$trt==1]
ipw.tr0 <- 1/(1-mat$pps[mat$trt==0])
```

Finalement, nous appliquons la formule d'estimation de l'effet causal par *IP Weighting*.

```
#Calcul de l'effet causal moyen par IP Weighting
treatment.effect <- (1/n_size)*sum(mat$rep[mat$trt==1]*ipw.tr1)
                      - (1/n_size)*sum(mat$rep[mat$trt==0]*ipw.tr0)
```

Nous refaisons cette simulation plusieurs fois, et nous agrègeons les estimations de l'effet causal du traitement sur la réponse. Dans notre exemple, nous obtenons une estimation de 168, qui est proche de la vrai valeur de 165.

```
> summary(treatment.effects)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  148.8   163.3   165.5   168.3   171.2   199.3
> print(avg.treatment.effect)
[1] 168.3245
```

6 Conclusion

Nous avons vu les concepts de base de l'inférence causale et nous avons défini l'effet causal moyen, une mesure fréquemment estimée en inférence causale, puisqu'elle représente la véritable relation entre le traitement et la réponse. Nous avons exploré comment il est possible de représenter les relations causales de manière graphique en utilisant des graphes orientés acycliques, que nous avons appelés diagrammes causaux. Nous avons également discuté de la variable confondante et de la manière dont sa présence complique l'estimation de l'effet causal. Nous avons introduit le critère de la porte arrière, qui permet de déterminer la condition d'interchangeabilité conditionnelle est atteinte, en tenant compte d'un ensemble de covariables. Nous avons vu comment cela nous aide à estimer l'effet causal moyen, notamment à l'aide de la méthode de pondération par probabilité inverse. Enfin, nous avons vu comment programmer une simulation en R.

Même si cela semble beaucoup, ce n'est que la surface de l'inférence causale. Il existe plusieurs autres situations à prendre en compte, comme les traitements qui varient dans le temps, ainsi que des techniques d'estimation complémentaires, telles que l'estimation par variable instrumentale et la G-estimation des modèles imbriqués structurels, permettant d'approfondir notre compréhension des relations causales et d'améliorer la précision de nos estimations.

Merci

7 Annexe

```r
#Rends l'aleatoire deterministe
set.seed(2)
#Taille de l'echantillon
n_size <-  100
#Taille de la simulation
n_sim <- 100

#Definition des parametre du traitement
beta0 <- 0.02 ; beta1 <- 0.012

#Distribution de l'age
agemean <- 45; agesd <- 8

#Definition des parametres de la reponse
beta0.r <- 75 ; beta1.r <- 8.5; beta2.r <- 165

treatment.effects <- numeric(n_sim)

for (k in 1:n_sim) {
  #Definition de la matrice
  mat <- data.frame(matrix(NA, nrow=n_size, ncol = 0))

  #Simulation de l'age
  sim.age <- rnorm(n_size, agemean, agesd)
  mat$age <- sim.age

  #Calcul des probabilites de traitement
  prt <- beta0 + beta1*mat$age
  mat$trt <- rbinom(n_size, 1, prt)

  #Distribution de la reponse avec erreur normal(0,1)
  eps <- rnorm(n_size, 0, 1)
  mat$rep <- beta0.r + beta1.r*mat$age + beta2.r*mat$trt + eps

  #Modelisation des scores de propension et cacul de ceux-ci
  exp.model <- glm(mat$trt ~ mat$age , data=mat, family = "binomial")
  propensity.score <- predict(exp.model, type="response")
  mat$pps <- propensity.score

  #Calcul des poids de la methode IP Weighting
  ipw.tr1 <- 1/mat$pps[mat$trt==1]
  ipw.tr0 <- 1/(1-mat$pps[mat$trt==0])

  #Calcul de l'effet causal moyen par IP Weighting
  treatment.effect <- (1/n_size)*sum(mat$rep[mat$trt==1]*ipw.tr1) - (1/n_size)*sum(mat$rep[mat
  treatment.effects[k] <- treatment.effect
}

#Moyenne des simulations
avg.treatment.effect <- mean(treatment.effects)

#Sortie
summary(treatment.effects)
print(avg.treatment.effect)
```

8 Reference

Les livres utilisés :

— Causal Inference : What If by Miguel A. Hernán and James M. Robins.
— Fundamentals of Causal Inference with R by Babette A. Brumback.